MỤC LỤC

DANH MỤC TỪ VIẾT TẮT 5
LỜI MỞ ĐẦU 7
GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU 8
1.1. Nguồn và phạm vi dữ liệu 8
1.2. Cấu trúc, thống kê mô tả và chất lượng dữ liệu 8
Bảng 1. Số lượng và tỷ lệ thiếu theo toàn bộ thuộc tính 8
GIAI ĐOẠN 2: LÀM SẠCH VÀ CHUẨN BỊ DỮ LIỆU 9
2.1. Các bước thực hiện và minh chứng 9
2.2. Giải trình lựa chọn kỹ thuật 9
GIAI ĐOẠN 3: THỐNG KÊ, TRỰC QUAN HÓA VÀ KIỂM ĐỊNH 9
3.1. Tỉ lệ sống sót 9
Bảng kết quả từ notebook 9
3.2. Sự liên hệ giữa giới tính và tỉ lệ sống sót 10
Bảng kết quả từ notebook 10
3.3. Sự liên hệ giữa hạng vé và tỉ lệ sống sót 11
Bảng kết quả từ notebook 11
3.4. Mối liên hệ giữa hạng vé và sống sót có khác nhau theo giới tính? 12
Bảng kết quả từ notebook 12
3.5. Sự liên hệ giữa tuổi và tỉ lệ sống sót 13
Bảng kết quả từ notebook 13
3.6. So sánh tỷ lệ sống sót khi đi một mình và đi cùng người thân 14
Bảng kết quả từ notebook 14
3.7. Kích thước nhóm và tỉ lệ sống sốt 15
Bảng kết quả từ notebook 15
3.8. Giới tính và tình trạng sống sót có liên quan không? 16
Bảng kết quả từ notebook 16
3.9. Giá vé và tỷ lệ sống sót: phân tích trong từng hạng vé 17
Bảng kết quả từ notebook 17
3.10. Đồng thời xem xét tuổi, giới tính và hạng vé 18
Bảng kết quả từ notebook 18
3.11. Danh xưng trong tên hành khách 20
Bảng kết quả từ notebook 20
3.12. Cảng lên tàu: sự khác biệt có ý nghĩa thống kê không? 21

Bảng chéo cảng × sống sót..... 21
Tỷ lệ sống sót theo cảng..... 21
3.13. Khoảng tin cậy 95% cho tỷ lệ sống sót..... 22
Bảng kết quả từ notebook..... 22
MÔ HÌNH DỰ ĐOÁN SỐNG SÓT..... 24
3.14. Tạo đặc trưng và chia tập huấn luyện/kiểm tra..... 24
3.15. Pipeline tiền xử lý và bốn mô hình..... 24
3.16. Đánh giá nền tảng bằng Stratified Cross-Validation..... 24
Bảng kết quả 5-fold cross-validation trước tuning..... 24
3.17. Hyperparameter tuning bằng RandomizedSearchCV..... 25
Kết quả ROC-AUC CV sau tuning và tham số tốt nhất..... 25
3.18. Đánh giá cuối cùng trên tập validation..... 26
Bảng chỉ số validation của cả bốn mô hình..... 26
3.19. Giải thích mô hình tốt nhất bằng Permutation Importance..... 27
Tầm quan trọng đặc trưng theo mức giảm ROC-AUC..... 27
3.20. Diễn giải bổ sung: Logistic Regression và cây quyết định..... 28
Hệ số Logistic Regression có độ lớn tuyệt đối cao..... 28
3.21. Kiểm tra overfitting: so sánh train và validation nội bộ của mô hình đã chọn. 29
3.22. Dự đoán trên test.csv chính thức của Kaggle và xuất submission.csv..... 30
Năm dòng đầu của submission.csv..... 30
KẾT LUẬN, HẠN CHẾ VÀ KHUYẾN NGHỊ..... 31
Phát hiện chính..... 31
Kết quả dự đoán và ý nghĩa ứng dụng..... 31
Giới hạn dữ liệu và phương pháp..... 31
Khuyến nghị và hướng mở rộng..... 31
PHỤ LỤC. CÁC BẢNG THỐNG KÊ BỔ SUNG..... 33
A.1. Năm dòng đầu train.csv..... 33
Bảng A1a. Thông tin hành khách và trạng thái..... 33
Bảng A1b. Nhóm gia đình và thông tin vé..... 33
A.2. Thống kê mô tả toàn bộ 12 biến..... 33
Bảng A2a. Số lượng, nhóm giá trị và trung bình..... 33
Bảng A2b. Phân vị và giá trị biên..... 34
A.3. Năm dòng sau tiền xử lý..... 34
Bảng A3. Bản ghi đã tạo đặc trưng..... 34
A.4. Diễn giải các kết quả từ notebook..... 35
TÀI LIỆU..... 36

DANH MỤC TỪ VIẾT TẮT

STT	Ký hiệu chữ viết tắt	Chữ viết đầy đủ
1	**Age**	Tuổi của hành khách
2	**AUC**	Area Under Curve (Diện tích dưới đường cong ROC)
3	**Cabin**	Số phòng hoặc vị trí cabin của hành khách
4	**CV**	Cross-Validation (Kiểm định chéo)
5	**EDA**	Exploratory Data Analysis (Phân tích dữ liệu khám phá)
6	**Embarked**	Cảng lên tàu (C: Cherbourg, Q: Queenstown, S: Southampton)
7	**F1**	F1-Score (Chỉ số đo lường độ chính xác của mô hình dựa trên Precision và Recall)
8	**Fare**	Giá vé hành khách

9	**IQR**	Interquartile Range (Khoảng tứ phân vị)
10	**Parch**	Parents / Children Aboard (Số lượng cha mẹ hoặc con cái đi cùng hành khách)
11	**Pclass**	Passenger Class (Hạng vé hành khách: Hạng 1, Hạng 2, Hạng 3)
12	**ROC**	Receiver Operating Characteristic (Đường cong đặc trưng hoạt động của mô hình)
13	**Sex**	Giới tính của hành khách
14	**SibSp**	Siblings / Spouses Aboard (Số lượng anh chị em hoặc vợ/chồng đi cùng hành khách)
15	**Survived**	Trạng thái sống sót của hành khách (0: Không sống sót, 1: Sống sót)
16	**Ticket**	Số hiệu vé hành khách

LỜI MỞ ĐẦU

Thảm họa chìm tàu Titanic năm 1912 không chỉ là một sự kiện lịch sử bi thương mà còn cung cấp một bộ dữ liệu kinh điển được sử dụng rộng rãi trong lĩnh vực Thống kê ứng dụng và Khoa học dữ liệu. Dưới góc độ phân tích định lượng, sự kiện này tạo nên một không gian thực nghiệm tự nhiên độc đáo để nghiên cứu các quyết định sinh tồn của con người trong điều kiện hoảng loạn và nguồn lực cứu hộ hữu hạn. Việc phân tích bộ dữ liệu Titanic không đơn thuần dừng lại ở việc mô tả bức tranh lịch sử, mà còn đóng vai trò như một bài toán chuẩn để áp dụng các kỹ thuật khai phá dữ liệu, kiểm định giả thuyết thống kê và xây dựng các mô hình phân loại nhị phân. Xuất phát từ tầm quan trọng đó, nghiên cứu này được thực hiện nhằm khảo sát tỷ lệ sống sót của hành khách, đánh giá mối liên hệ với các đặc điểm nhân khẩu học và điều kiện vé, đồng thời thử nghiệm và so sánh hiệu năng của bốn mô hình phân loại nhị phân hiện đại.

Để đạt được mục tiêu chung đó, nghiên cứu tiến hành giải quyết các mục tiêu cụ thể, bắt đầu từ việc khảo sát và đánh giá thực trạng cấu trúc dữ liệu, diện mạo nhân khẩu học như tuổi, giới tính, danh xưng, cùng các điều kiện hành trình bao gồm hạng vé, giá vé, cảng lên tàu và quy mô gia đình của hành khách. Tiếp đó, các kiểm định thống kê phi tham số và phép ước lượng khoảng tin cậy được thực hiện nhằm xác định các yếu tố có ý nghĩa thống kê tác động trực tiếp đến tỷ lệ sống sót. Trên cơ sở này, nghiên cứu tiến hành xây dựng, tối ưu hóa siêu tham số và đánh giá so sánh hiệu năng của bốn mô hình học máy gồm Hồi quy Logistic, Cây quyết định, Rừng ngẫu nhiên và XGBoost trong bài toán dự đoán phân loại nhị phân. Sau cùng, các phát hiện cốt lõi về mặt phương pháp luận được tổng hợp nhằm chỉ ra những giới hạn của dữ liệu thực nghiệm và đề xuất hướng mở rộng cho các nghiên cứu tiếp theo.

Đối tượng nghiên cứu của bài báo cáo là tỷ lệ sống sót và các thuộc tính liên quan của 891 hành khách thuộc tập huấn luyện cùng 418 hành khách thuộc tập kiểm tra thu thập từ nền tảng Kaggle. Phạm vi nghiên cứu tập trung vào việc áp dụng phân tích thống kê mô tả, kiểm định giả thuyết, phát triển pipeline tiền xử lý, huấn luyện và đánh giá mô hình học máy có giám sát. Toàn bộ số liệu, bảng thống kê và biểu đồ trực quan trong báo cáo đều được kết xuất trực tiếp từ các kết quả thực nghiệm đã lưu trong notebook, tuyệt đối không sử dụng hay thay thế bằng các kết quả mô phỏng.

Về phương pháp luận, tiểu luận áp dụng kết hợp chặt chẽ giữa phân tích thống kê cổ điển và các kỹ thuật học máy hiện đại. Trong giai đoạn tiền xử lý, dữ liệu thiếu được điền bằng các kỹ thuật thế vị thích hợp như dùng giá trị trung vị cho biến số và yếu vị

cho biến phân loại; các quan sát dị biệt về giá vé được nhận diện qua quy tắc khoảng biến thiên giữa các phân vị (IQR); đồng thời các đặc trưng mới được trích xuất như danh xưng, quy mô gia đình, trạng thái đi một mình và giá vé trung bình theo người. Trong giai đoạn phân tích thống kê, bài viết sử dụng phân tích bảng chéo, biểu đồ nhiệt, kiểm định độc lập Chi-squared để đánh giá mối tương quan phân loại, đo lường độ mạnh liên kết bằng hệ số Cramér's V, và ước lượng khoảng tin cậy 95% Wilson cho các phân nhóm mẫu. Đối với bài toán học máy, một pipeline xử lý dữ liệu khép kín được triển khai nhằm chống rò rỉ thông tin; dữ liệu được phân chia theo tỷ lệ 80/20 có phân tầng; hiệu năng mô hình cơ sở được đánh giá bằng phương pháp xác thực chéo phân tầng 5 lớp; quá trình tinh chỉnh tham số triển khai qua công cụ RandomizedSearchCV với tiêu chí tối ưu hóa diện tích dưới đường cong ROC (ROC-AUC); và mô hình chọn lọc được giải thích chuyên sâu thông qua kỹ thuật Permutation Importance.

Toàn bộ quy trình xử lý, tính toán và mô hình hóa nói trên được thực thi bằng ngôn ngữ lập trình Python trong môi trường Jupyter Notebook. Các thư viện bổ trợ chuyên dụng được khai thác bài bản bao gồm Pandas và NumPy cho thao tác cấu trúc dữ liệu; Matplotlib và Seaborn cho trực quan hóa đồ thị; Scipy cho các phép kiểm định thống kê; cùng Scikit-learn và XGBoost cho việc phát triển các thuật toán học máy.

GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU

1.1. Nguồn và phạm vi dữ liệu

- Nguồn dữ liệu: https://github.com/hnhun2306b5tneu-crypto/Titanic/tree/main/data
- Nguồn dữ liệu gốc: https://www.kaggle.com/competitions/titanic/data

1.2. Cấu trúc, thống kê mô tả và chất lượng dữ liệu

Nhóm dùng shape, info(), describe(), isna() và duplicated() để nhận diện kiểu biến, mức thiếu dữ liệu và bản ghi trùng. Kết quả cho thấy Age thiếu 177 dòng (19,87%), Cabin thiếu 687 dòng (77,10%) và Embarked thiếu 2 dòng (0,22%); không phát hiện dòng trùng hoàn toàn hoặc PassengerId trùng.

Bảng 1. Số lượng và tỷ lệ thiếu theo toàn bộ thuộc tính

Số giá trị thiếu	Tỷ lệ thiếu (%)
687	77.1
177	19.87
2	0.22
0	0
0	0
0	0
0	0
0	0
0	0
0	0
0	0
0	0

Thống kê mô tả 12 biến và năm bản ghi đầu được giữ ở phụ lục nhằm bảo toàn thông tin mà không làm bảng chính quá rộng.

GIAI ĐOẠN 2: LÀM SẠCH VÀ CHUẨN BỊ DỮ LIỆU

2.1. Các bước thực hiện và minh chứng

Notebook sao chép dữ liệu, kiểm tra trùng PassengerId (không có dòng bị loại), điền hai giá trị Embarked bằng mode và tạo các biến Nhom_tuoi, So_nguoi_than, Di_mot_minh, Trang_thai. Sau làm sạch vẫn còn 891 hành khách.

Quy tắc IQR nhận diện giá vé cao bất thường: ngưỡng Q3 + 1,5×IQR = 65,63; có 116 giá vé vượt ngưỡng. Notebook giữ các quan sát này vì vượt ngưỡng thống kê không chứng tỏ dữ liệu sai.

2.2. Giải trình lựa chọn kỹ thuật

- Age: giữ thiếu trong thống kê chung; chỉ bỏ khi phân tích tuổi để tránh làm sai lệch phân bố quan sát.
- Embarked: điền mode vì đây là biến phân loại với chỉ hai giá trị thiếu.
- Cabin: không dùng cho phân tích mô tả chính do thiếu 77,10%.
- Trùng lặp: kiểm tra trên PassengerId; không có dòng bị xóa.
- Fare: dùng IQR để phát hiện, giữ lại các vé cao.
- Mã hóa và chuẩn hóa: chưa cần trong EDA; được đưa vào pipeline riêng của phần Machine Learning, fit trên dữ liệu train.

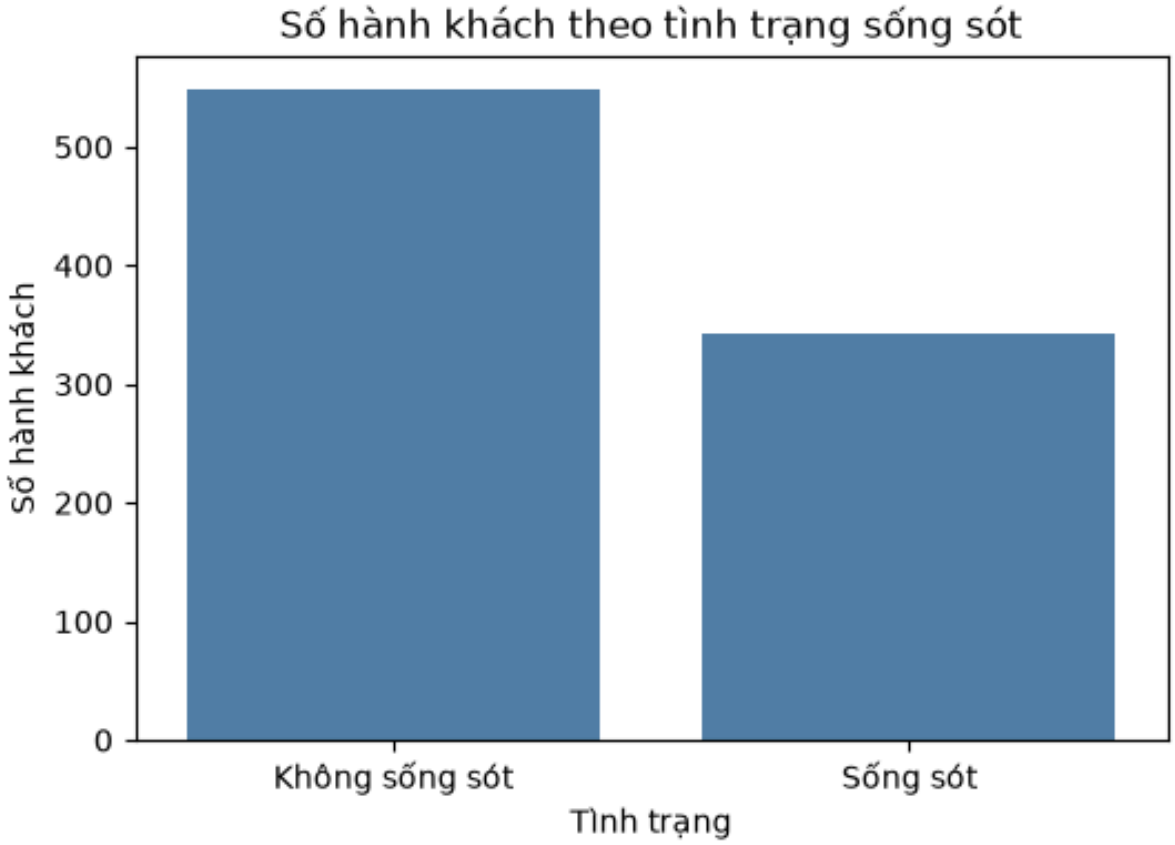
GIAI ĐOẠN 3: THỐNG KÊ, TRỰC QUAN HÓA VÀ KIỂM ĐỊNH

3.1. Tỉ lệ sống sót

Cách thực hiện: Đếm trạng thái sống sót và tính trung bình Survived (biến nhị phân).

Bảng kết quả từ notebook

Trang_thai	Số hành khách
Không sống sót	549
Sống sót	342



Hình 1. Số người sống sót và không sống sót

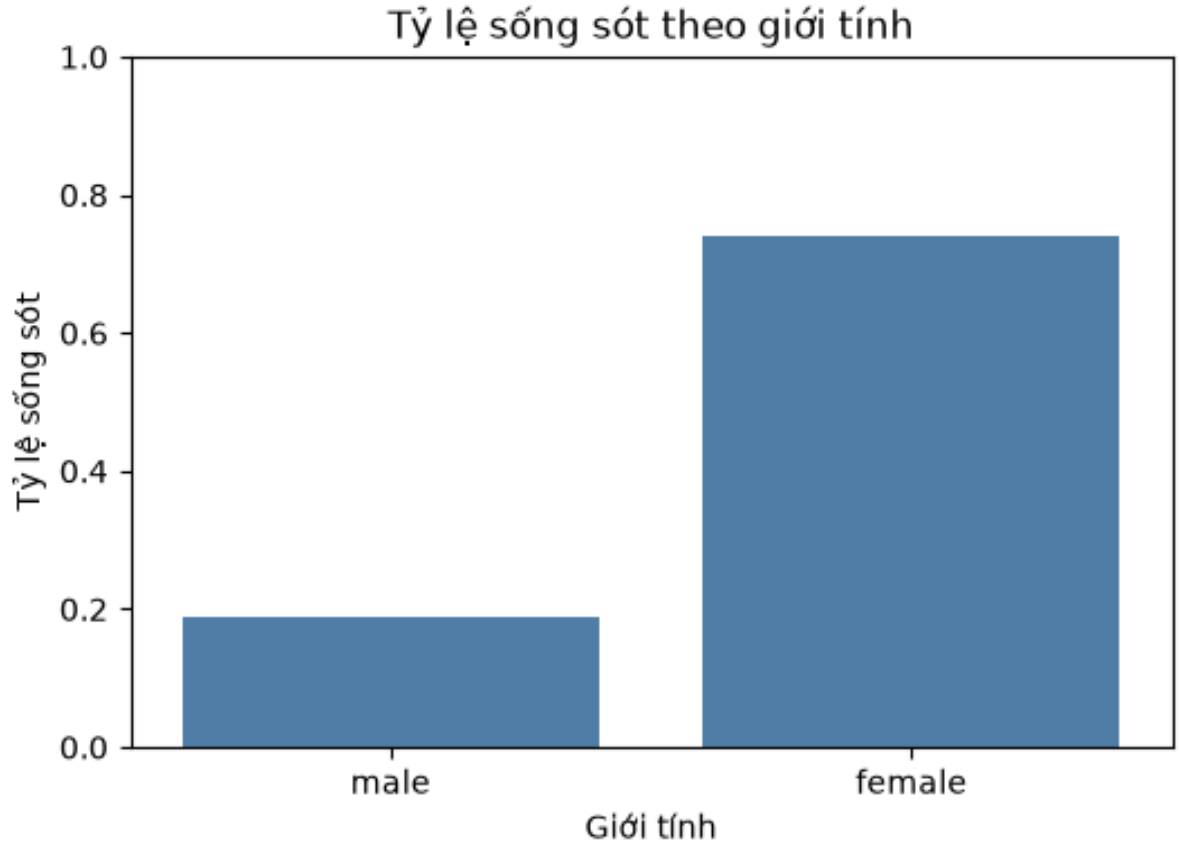
Kết quả và nhận xét: 342/891 hành khách sống sót (38,4%); 549 không sống sót (61,6%). Đây là mức tham chiếu cho các phân tích nhóm. Tỷ lệ không sống sót lớn hơn tỷ lệ sống sót 23,2 điểm phần trăm. Con số 38,4% là mốc chung; khi so sánh các nhóm cần dùng đúng mẫu số của từng nhóm, không lấy số người sống sót chia cho toàn bộ 891 hành khách.

3.2. Sự liên hệ giữa giới tính và tỉ lệ sống sót

Cách thực hiện: Nhóm theo Sex rồi tính số hành khách và tỷ lệ sống sót của từng nhóm.

Bảng kết quả từ notebook

Sex	count	Tỷ lệ sống (%)
female	314	74.2
male	577	18.9



Hình 2. Tỷ lệ sống sót theo giới tính

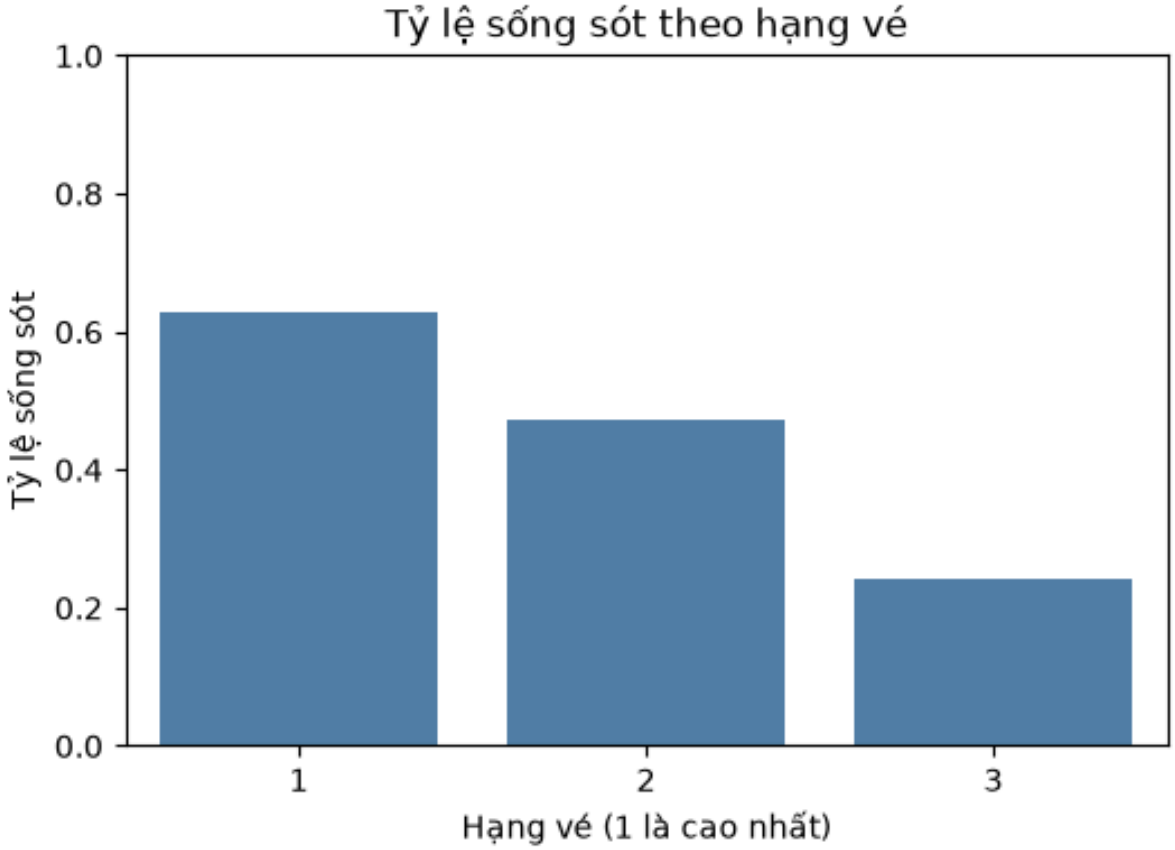
Kết quả và nhận xét: Nữ đạt 74,2% (314 người trong mẫu); nam đạt 18,9% (577 người). Khoảng cách lớn cho thấy mối liên hệ mạnh trong dữ liệu. Nữ có 233 người sống trong 314 hành khách, còn nam là 109/577; chênh lệch khoảng 55,3 điểm phần trăm. Tỷ lệ nữ cao hơn gần bốn lần tỷ lệ nam, nhưng phân tích này chưa tách ảnh hưởng của tuổi và hạng vé.

3.3. Sự liên hệ giữa hạng vé và tỉ lệ sống sót

Cách thực hiện: Nhóm theo Pclass (1 đến 3), đếm quan sát và lấy trung bình Survived.

Bảng kết quả từ notebook

Pclass	count	Tỷ lệ sống (%)
1	216	63
2	184	47.3
3	491	24.2



Hình 3. Tỷ lệ sống sót theo hạng vé

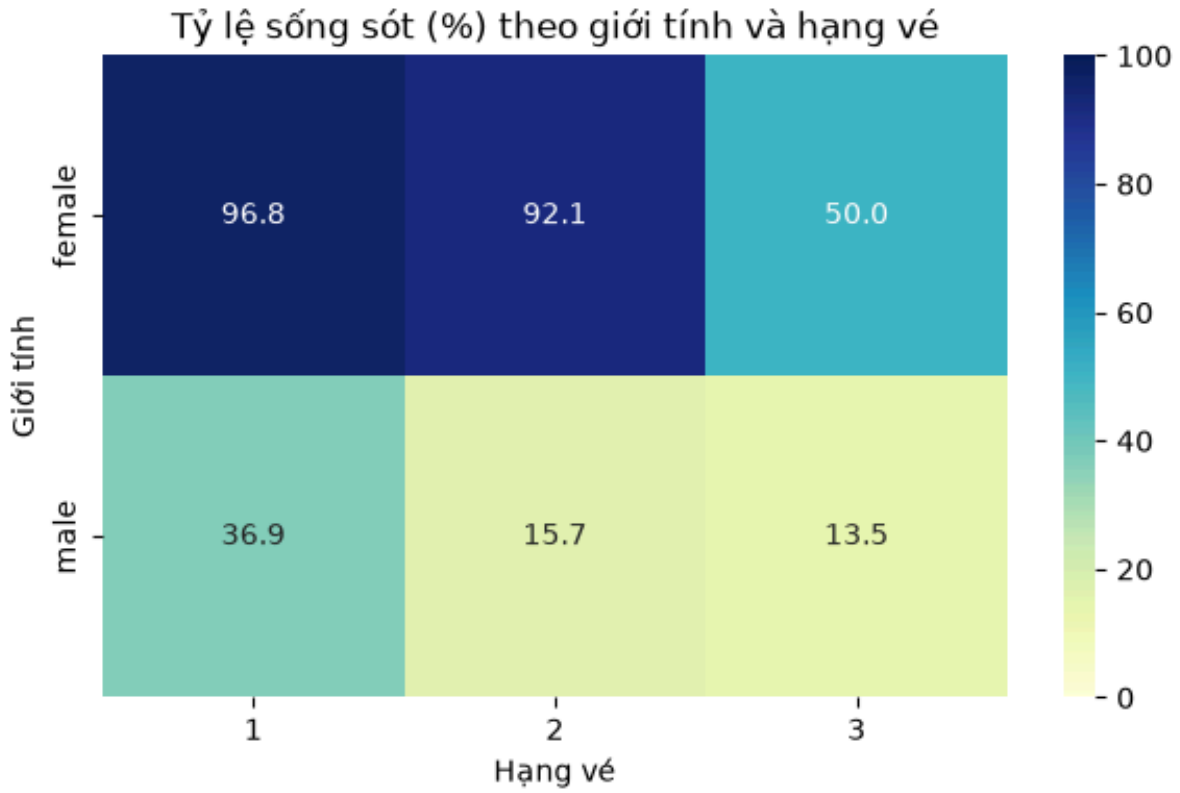
Kết quả và nhận xét: Tỷ lệ sống lần lượt 63,0%, 47,3%, 24,2% cho hạng 1, 2, 3; chênh 38,8 điểm phần trăm giữa hạng 1 và 3. Chênh lệch tỷ lệ giữa hạng 1 và hạng 3 là 38,8 điểm phần trăm; hạng 2 nằm giữa. Đây là khuynh hướng rõ trong mẫu và là lý do cần xét đồng thời Pclass với Sex thay vì quy kết mọi khác biệt cho hạng vé.

3.4. Mối liên hệ giữa hạng vé và sống sót có khác nhau theo giới tính?

Cách thực hiện: Tạo pivot_table Sex × Pclass với giá trị trung bình Survived, chuyển thành % và biểu diễn heatmap.

Bảng kết quả từ notebook

Pclass / Sex	1	2	3
female	96.8	92.1	50
male	36.9	15.7	13.5



Hình 4. Heatmap giới tính và hạng vé

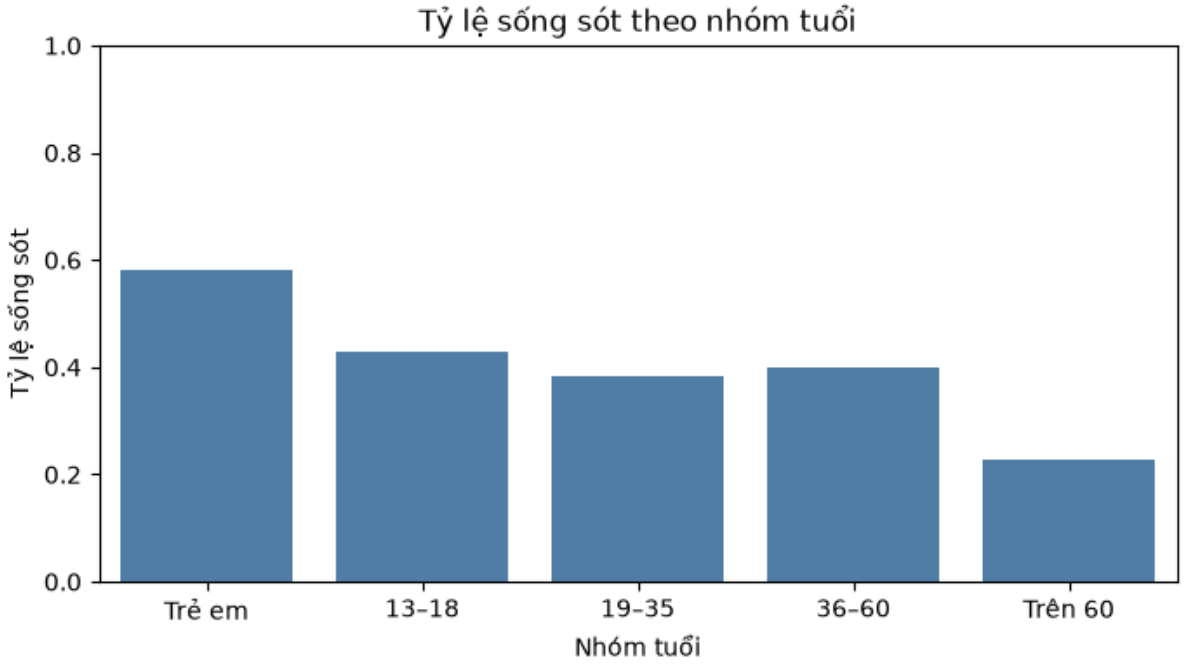
Kết quả và nhận xét: Nữ hạng 1 đạt 96,8% và nữ hạng 2 đạt 92,1%; nam hạng 3 chỉ 13,5%. Nữ hạng 3 (50%) vẫn cao hơn nam hạng 1 (36,9%). Sự chênh lệch theo giới tính tồn tại trong cả ba hạng vé, song mức chênh có khác nhau. Nữ hạng 3 (50,0%) vẫn cao hơn nam hạng 1 (36,9%); do vậy hai biến cần được xem đồng thời khi phân tích các nhóm hành khách.

3.5. Sự liên hệ giữa tuổi và tỉ lệ sống sót

Cách thực hiện: Chỉ dùng 714 hành khách có Age; chia thành năm khoảng tuổi rồi tính tỷ lệ sống từng nhóm.

Bảng kết quả từ notebook

Nhom_tuoi	count	Tỷ lệ sống (%)
Trẻ em	69	58
13-18	70	42.9
19-35	358	38.3
36-60	195	40
Trên 60	22	22.7



Hình 5. Tỷ lệ sống theo nhóm tuổi

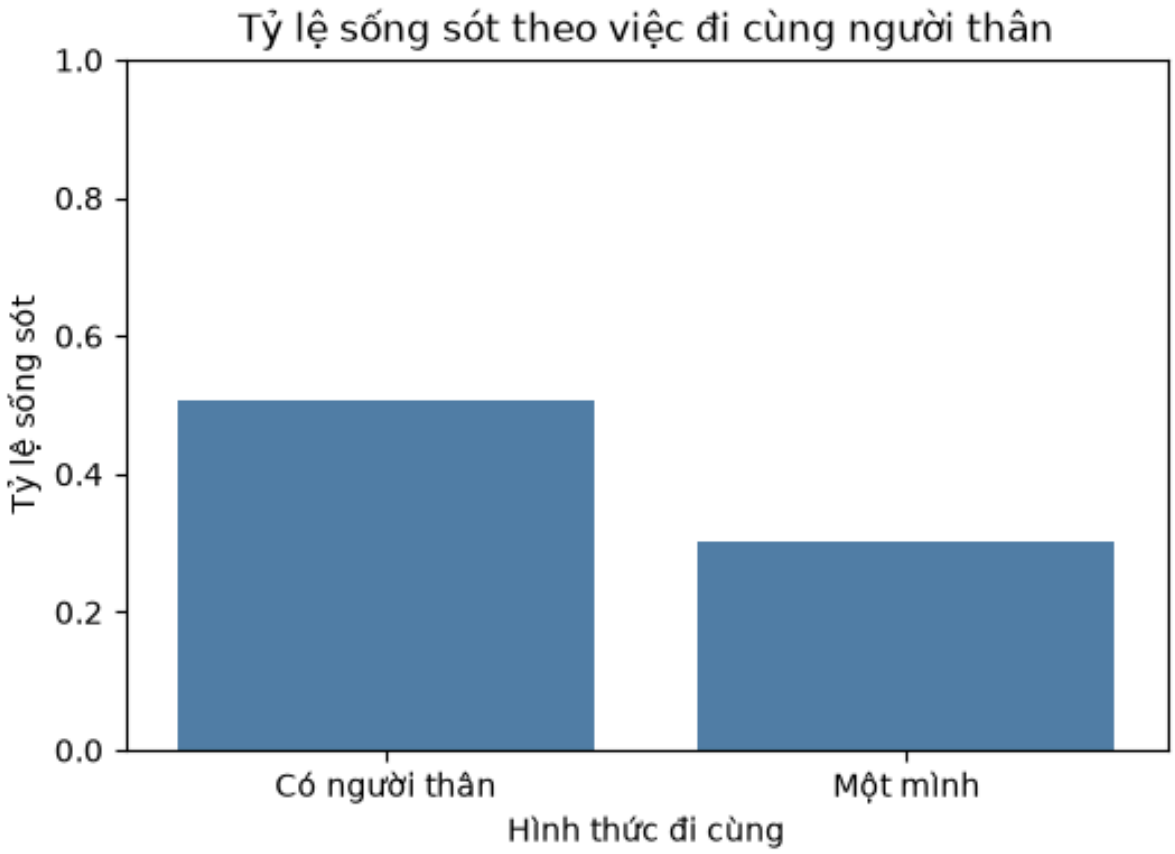
Kết quả và nhận xét: Nhóm trẻ em ≤12 tuổi đạt 58,0% (n=69); nhóm trên 60 tuổi đạt 22,7% (n=22). Mẫu nhỏ và 177 tuổi thiếu khiến việc khái quát cần thận trọng. Tỷ lệ không giảm đều theo tuổi: nhóm 36-60 đạt 40,0%, nhỉnh hơn nhóm 19-35 là 38,3%. Nhóm trên 60 chỉ có 22 người và 177 bản ghi thiếu Age không được dùng trong phép tính này, nên không kết luận tuổi tự thân quyết định khả năng sống.

3.6. So sánh tỷ lệ sống sót khi đi một mình và đi cùng người thân

Cách thực hiện: Tạo chỉ báo từ SibSp + Parch rồi so sánh hai nhóm đi một mình/có người thân.

Bảng kết quả từ notebook

Di_mot_minh	count	Tỷ lệ sống (%)
Có người thân	354	50.6
Một mình	537	30.4



Hình 6. So sánh hành khách đi một mình và đi cùng

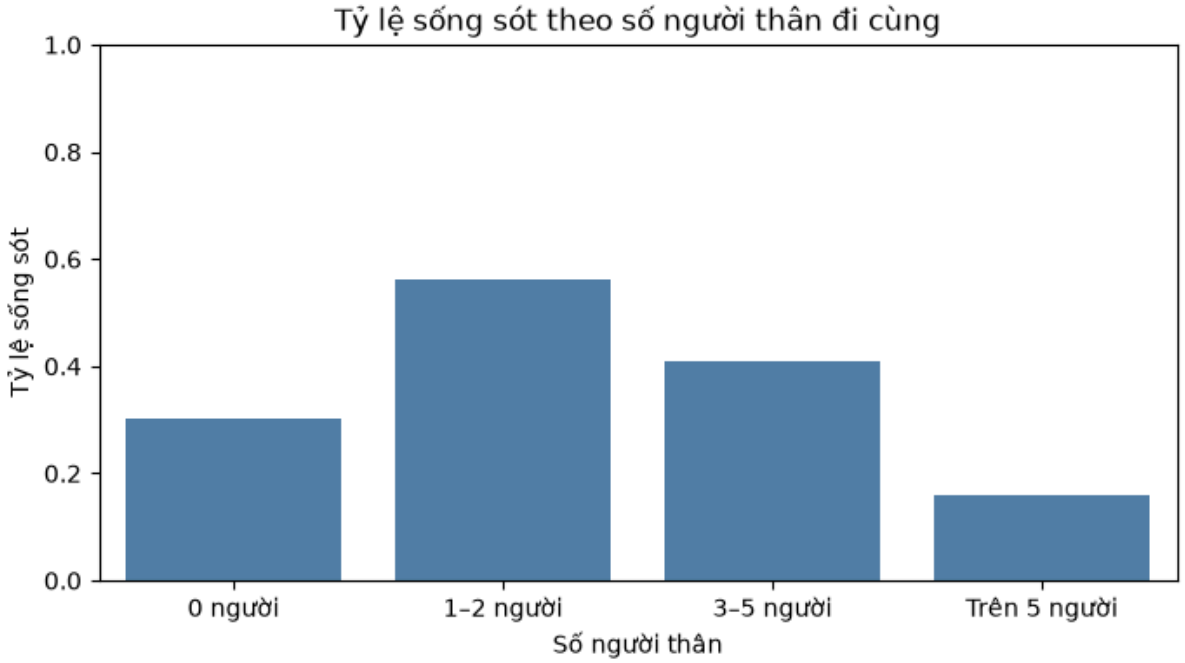
Kết quả và nhận xét: Có người thân: 50,6% (n=354); đi một mình: 30,4% (n=537). Đây là mối liên hệ quan sát, không phải bằng chứng tác động của việc đi cùng. Mức chênh là 20,2 điểm phần trăm. Tuy nhiên nhóm có người thân có thể khác nhóm đi một mình về tuổi, giới tính và hạng vé; kết quả cho thấy sự liên hệ quan sát chứ chưa chứng minh lợi ích nhân quả của việc đi cùng.

3.7. Kích thước nhóm và tỉ lệ sống sốt

Cách thực hiện: Phân số người thân đi cùng thành các mức 0, 1-2, 3-5, trên 5 để so sánh.

Bảng kết quả từ notebook

Nhom_gia_dinh	count	Tỷ lệ sống (%)
0 người	537	30.4
1-2 người	263	56.3
3-5 người	66	40.9
Trên 5 người	25	16



Hình 7. Tỷ lệ sống theo quy mô gia đình

Kết quả và nhận xét: Nhóm 1-2 người thân có tỷ lệ sống cao nhất 56,3% (n=263); nhóm trên 5 thấp nhất 16,0% nhưng chỉ có 25 quan sát. Nhóm có 1-2 người thân cao hơn nhóm đi một mình 25,9 điểm phần trăm. Xu hướng không tuyến tính, và kết quả 16,0% của nhóm trên 5 người cần đặc biệt thận trọng vì chỉ dựa trên 25 hành khách.

3.8. Giới tính và tình trạng sống sót có liên quan không?

Cách thực hiện: Lập bảng chéo Sex × Survived và kiểm định độc lập Chi-square ở $\alpha=0,05$.

Bảng kết quả từ notebook

Survived / Sex	0	1
female	81	233
male	468	109

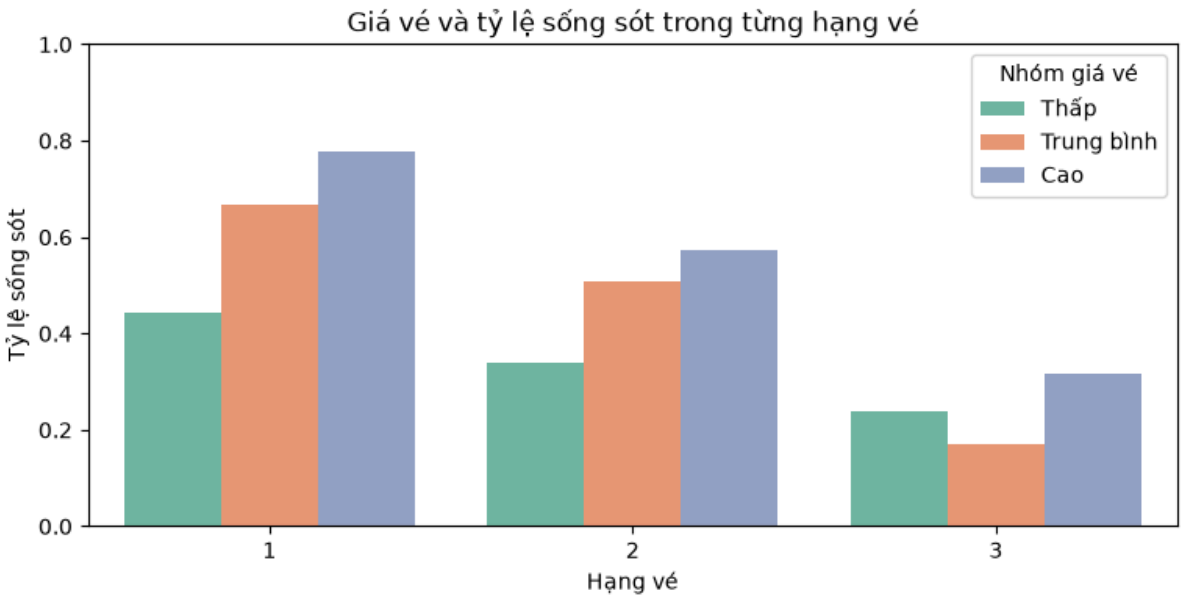
Kết quả và nhận xét: $p = 1,19736\times10^{-58} < 0,05$: bác bỏ giả thuyết hai biến độc lập. Kết quả chứng minh liên hệ thống kê, không xác lập nguyên nhân. Bảng chéo gồm nữ 233 sống/81 không sống và nam 109 sống/468 không sống. Vì p-value rất nhỏ, bác bỏ giả thuyết độc lập ở mức ý nghĩa 5%. Kiểm định không cho biết độ mạnh của liên hệ hoặc cơ chế gây ra khác biệt.

3.9. Giá vé và tỷ lệ sống sót: phân tích trong từng hạng vé

Cách thực hiện: Chia Fare thành ba mức phân vị bên trong từng Pclass, sau đó tính số quan sát và tỷ lệ sống.

Bảng kết quả từ notebook

Pclass	Nhom_gia_trong_hang	count	Tỷ lệ sống (%)
1	Thấp	72	44.4
1	Trung bình	72	66.7
1	Cao	72	77.8
2	Thấp	62	33.9
2	Trung bình	61	50.8
2	Cao	61	57.4
3	Thấp	164	23.8
3	Trung bình	163	17.2
3	Cao	164	31.7



Hình 8. Tỷ lệ sống theo phân vị giá vé trong từng hạng

Kết quả và nhận xét: Hạng 1: vé thấp/trung bình/cao có tỷ lệ 44,4%/66,7%/77,8%. Hạng 3 không tăng đều (23,8%/17,2%/31,7%), nên không thể kết luận giá vé có tác động độc lập. Trong hạng 2, nhóm giá thấp và cao lần lượt 33,9% và 57,4%; trong hạng 3, ba nhóm tương ứng 23,8%, 17,2% và 31,7%. Việc chia phân vị trong từng hạng chỉ làm giảm nhiễu do Pclass, chưa kiểm soát đồng thời các đặc điểm khác và không xác lập quan hệ nhân quả.

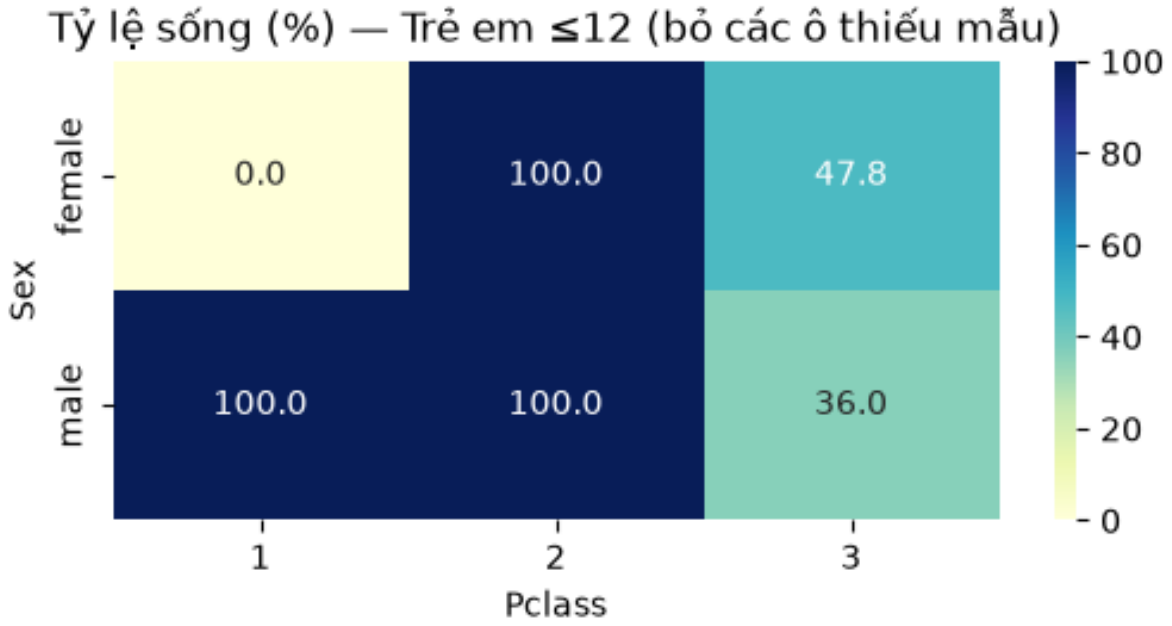
3.10. Đồng thời xem xét tuổi, giới tính và hạng vé

Cách thực hiện: Chia tuổi thành ba mức (≤12, 13-50, >50) rồi tổng hợp theo Sex và Pclass, vẽ ba heatmap.

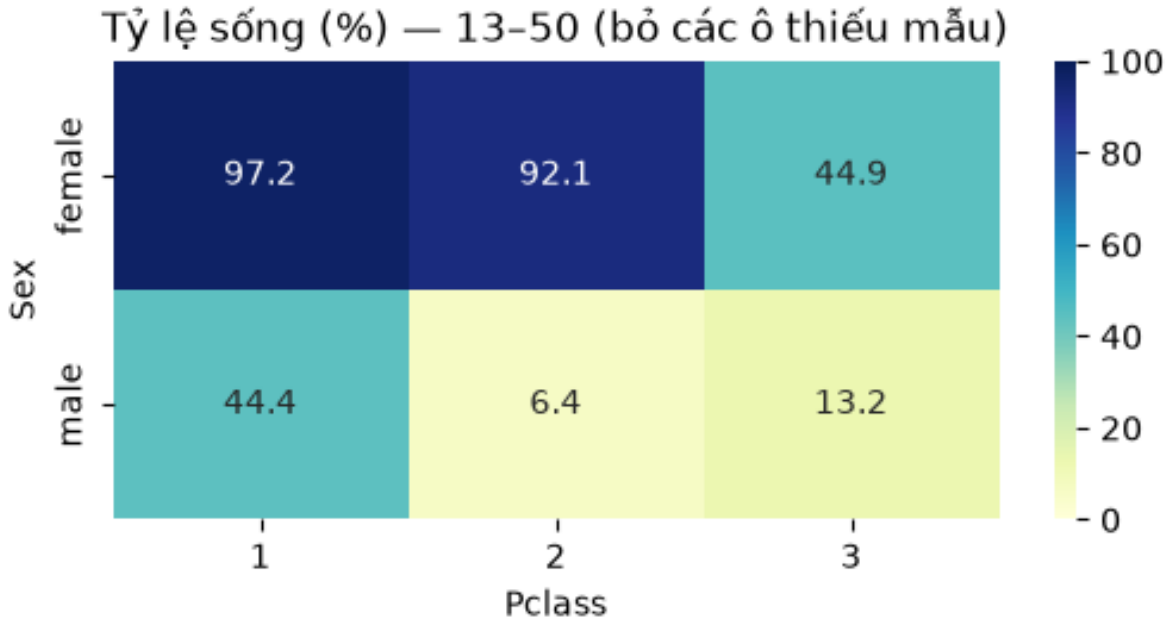
Bảng kết quả từ notebook

Sex	Pclass	Tuoi_3_nhom	count	Tỷ lệ sống (%)
female	1	Trẻ em ≤12	1	0
female	1	13-50	71	97.2
female	1	Trên 50	13	100
female	2	Trẻ em ≤12	8	100
female	2	13-50	63	92.1
female	2	Trên 50	3	66.7
female	3	Trẻ em ≤12	23	47.8
female	3	13-50	78	44.9
female	3	Trên 50	1	100
male	1	Trẻ em ≤12	3	100

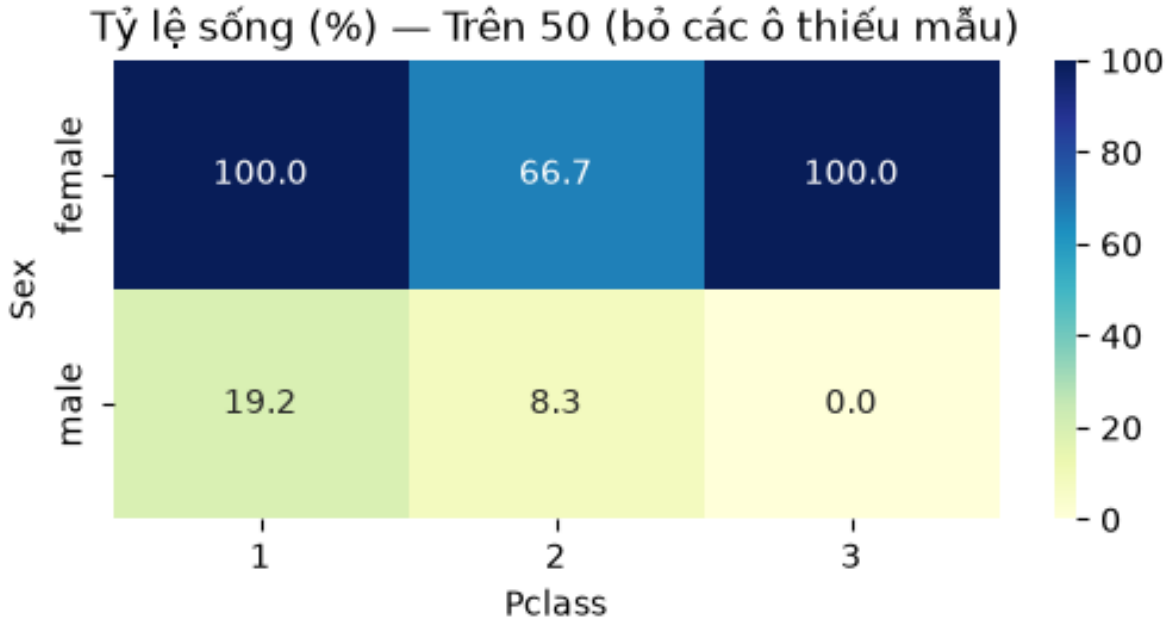
male	1	13-50	72	44.4
male	1	Trên 50	26	19.2
male	2	Trẻ em ≤12	9	100
male	2	13-50	78	6.4
male	2	Trên 50	12	8.3
male	3	Trẻ em ≤12	25	36
male	3	13-50	219	13.2
male	3	Trên 50	9	0



Hình 9. Heatmap tỷ lệ sống theo tuổi, giới và hạng vé (biểu đồ 1)



Hình 10. Heatmap tỷ lệ sống theo tuổi, giới và hạng vé (biểu đồ 2)



Hình 11. Heatmap tỷ lệ sống theo tuổi, giới và hạng vé (biểu đồ 3)

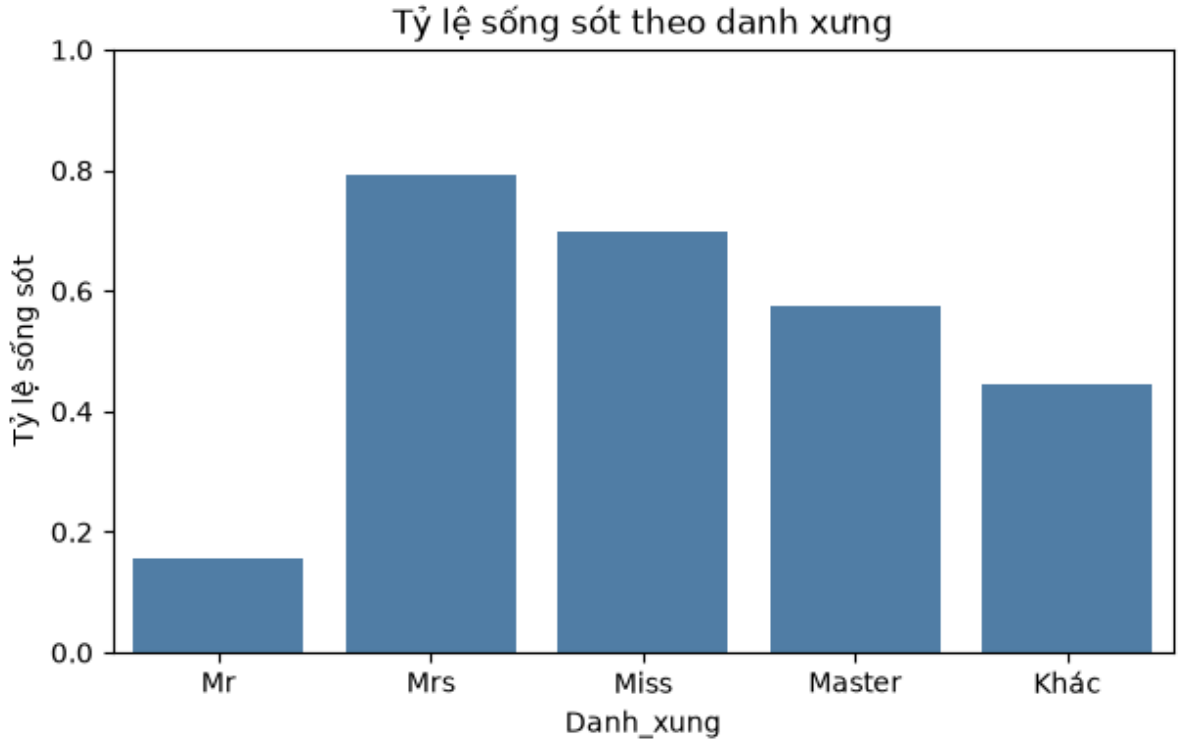
Kết quả và nhận xét: Tỷ lệ sống khác biệt lớn giữa các tổ hợp. Một số ô chỉ có 1-3 người, nên giá trị 0% hoặc 100% không phản ánh ước lượng ổn định. Ba heatmap cho thấy một số khác biệt chỉ xuất hiện ở những tổ hợp cụ thể. Các ô ít mẫu có thể cho tỷ lệ cực đoan 0% hoặc 100%; phải kiểm tra số quan sát trước khi so sánh, nhất là nhóm tuổi nhỏ hoặc nhóm tuổi cao theo từng hạng.

3.11. Danh xưng trong tên hành khách

Cách thực hiện: Tách Mr, Mrs, Miss, Master và nhóm Khác từ Name, rồi đếm và so sánh tỷ lệ sống.

Bảng kết quả từ notebook

Danh_xung	count	Tỷ lệ sống (%)
Mr	517	15.7
Miss	182	69.8
Mrs	125	79.2
Master	40	57.5
Khác	27	44.4



Hình 12. Tỷ lệ sống theo danh xưng

Kết quả và nhận xét: Mrs đạt 79,2% (n=125), Miss 69,8% (n=182), Master 57,5% (n=40), Mr 15,7% (n=517). Danh xưng phản ánh đồng thời nhiều đặc điểm xã hội và nhân khẩu học. Khoảng cách giữa Mrs (79,2%) và Mr (15,7%) rất lớn. Tuy nhiên danh xưng được suy ra từ tên và đồng thời phản ánh giới tính, tuổi hoặc tình trạng hôn nhân; nó là đặc trưng hữu ích cho mô hình, không phải một nguyên nhân độc lập đã được chứng minh.

3.12. Cảng lên tàu: sự khác biệt có ý nghĩa thống kê không?

Cách thực hiện: Tạo bảng Embarked × Survived, tính tỷ lệ sống từng cảng, Chi-square và Cramér's V.

Bảng chéo cảng × sống sót

Survived / Embarked	0	1
C	75	93
Q	47	30
S	427	219

Tỷ lệ sống sót theo cảng

Embarked	Tỷ lệ sống (%)
C	55.4
Q	39
S	33.9

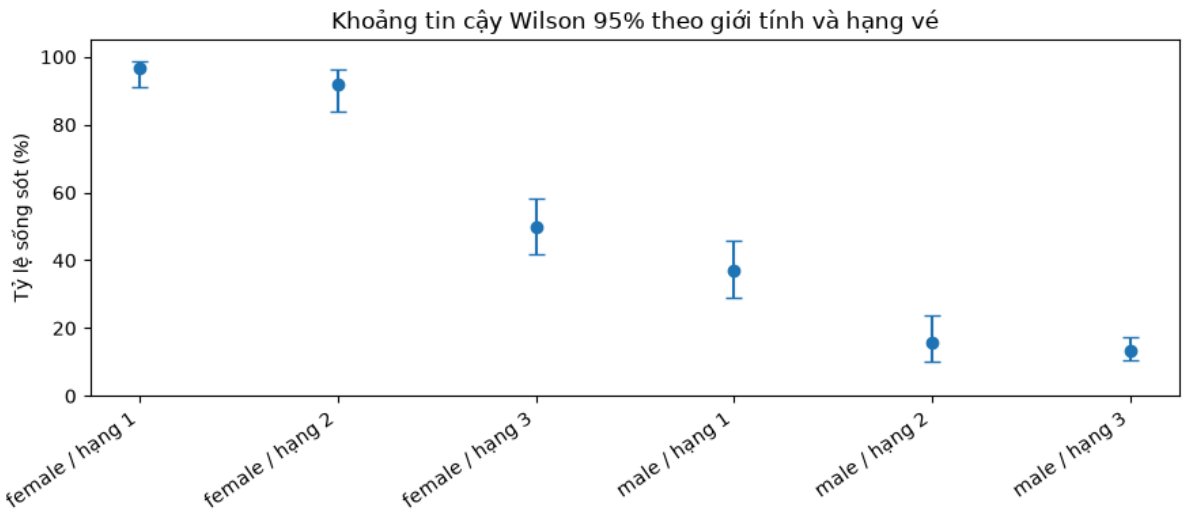
Kết quả và nhận xét: C: 55,4%; Q: 39,0%; S: 33,9%. Chi-square $p=2{,}30086\times10^{-6}$ và Cramér's V=0,171: có liên hệ thống kê, độ mạnh tương đối nhỏ. Cảng C cao hơn S 21,5 điểm phần trăm. P-value cho thấy mối liên hệ có ý nghĩa thống kê, nhưng Cramér's V=0,171 hàm ý mức liên hệ không lớn; sự phân bố khác nhau về hạng vé và giới tính theo cảng có thể góp phần tạo ra chênh lệch.

3.13. Khoảng tin cậy 95% cho tỷ lệ sống sót

Cách thực hiện: Tính khoảng tin cậy Wilson theo từng nhóm Sex × Pclass để biểu diễn mức bất định.

Bảng kết quả từ notebook

Sex	Pclass	count	sum	Tỷ lệ (%)	CI dưới (%)	CI trên (%)
female	1	94	91	96.8	91	98.9
female	2	76	70	92.1	83.8	96.3
female	3	144	72	50	41.9	58.1
male	1	122	45	36.9	28.8	45.7
male	2	108	17	15.7	10.1	23.8
male	3	347	47	13.5	10.3	17.5



Hình 13. Tỷ lệ sống và khoảng tin cậy Wilson 95%

Kết quả và nhận xét: Nữ hạng 1: 96,8% (CI 91,0-98,9%); nam hạng 3: 13,5% (CI 10,3-17,5%). Khoảng tin cậy giúp đọc tỷ lệ theo cả độ lớn mẫu. Hai khoảng tin cậy Wilson cách xa nhau, củng cố nhận xét về chênh lệch trong mẫu. Điểm quan trọng là khoảng tin cậy rộng hơn khi nhóm nhỏ: nên xem cả cỡ mẫu và biên độ khoảng tin cậy trước khi kết luận.

MÔ HÌNH DỰ ĐOÁN SỐNG SÓT

3.14. Tạo đặc trưng và chia tập huấn luyện/kiểm tra

Bài toán phân loại nhị phân dự đoán Survived. Notebook thêm Danh_xung, So_nguoi_than, Di_mot_minh_so và Gia_ve_moi_nguoi, sau đó chia tập train.csv theo tỷ lệ 80/20 có stratify: 712 dòng huấn luyện, 179 dòng validation; tỷ lệ sống sót lần lượt 38,3% và 38,5%. Các đặc trưng được tạo trước khi đưa vào pipeline; cần phân biệt nhóm dùng để mô tả với đặc trưng dùng dự đoán. Chia dữ liệu theo stratify giúp tỷ lệ lớp sống sót tương đối ổn định giữa hai tập, phục vụ so sánh công bằng.

Việc mã hóa, điền giá trị thiếu và chuẩn hóa được đặt trong pipeline để học từ dữ liệu huấn luyện của từng fold, tránh rò rỉ thông tin validation vào quá trình fit.

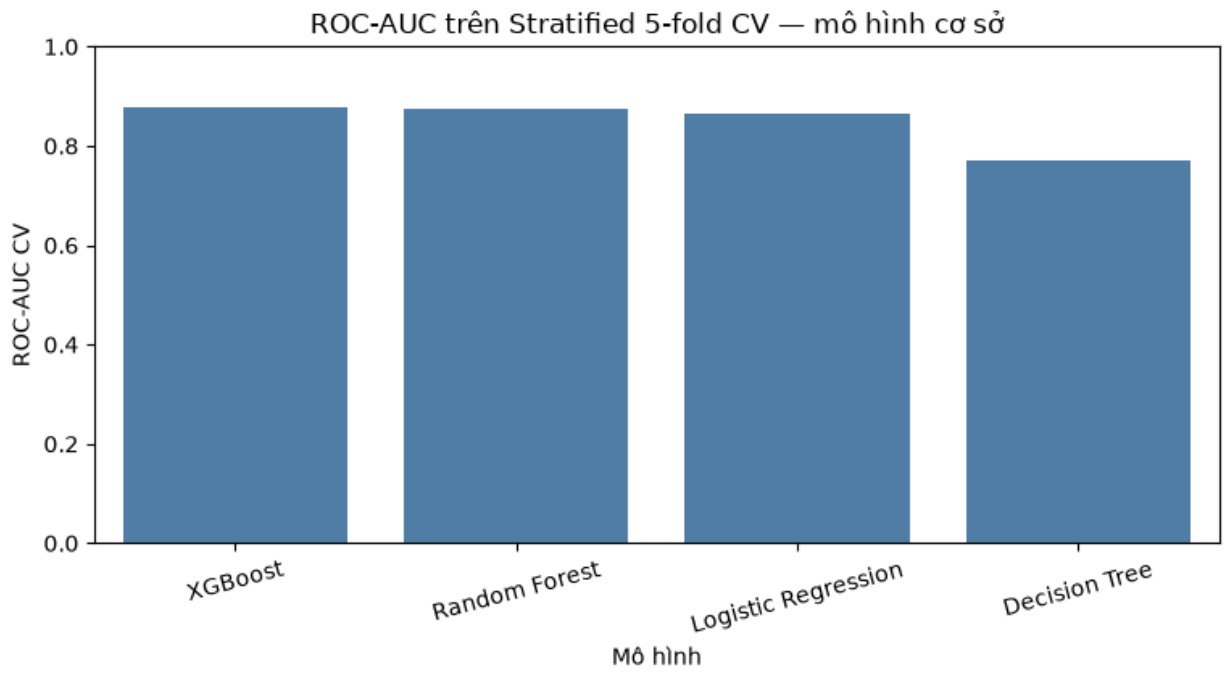
3.15. Pipeline tiền xử lý và bốn mô hình

Với biến số: điền median; biến phân loại: điền mode và One-Hot Encoding. Logistic Regression thêm bước StandardScaler; các mô hình cây sử dụng tiền xử lý phù hợp. Bốn mô hình: Logistic Regression, Decision Tree, Random Forest và XGBoost; cùng đánh giá bằng Stratified 5-Fold Cross-Validation. Pipeline giúp áp dụng cùng quy tắc biến đổi tại huấn luyện và dự đoán. Logistic Regression là mốc tuyến tính dễ giải thích; Decision Tree dễ quan sát quy tắc; Random Forest và XGBoost kiểm tra khả năng học quan hệ phi tuyến.

3.16. Đánh giá nền tảng bằng Stratified Cross-Validation

Bảng kết quả 5-fold cross-validation trước tuning

Mô hình	ROC-AUC CV	Độ lệch chuẩn AUC	Accuracy CV	F1 CV
XGBoost	0.879	0.016	0.806	0.74
Random Forest	0.876	0.017	0.808	0.748
Logistic Regression	0.866	0.02	0.823	0.763
Decision Tree	0.771	0.009	0.784	0.715



Hình 14. ROC-AUC cross-validation của bốn mô hình

XGBoost đạt ROC-AUC CV cao nhất trước tuning (0,879), Random Forest 0,876, Logistic Regression 0,866 và Decision Tree 0,771. Trong khi đó Logistic Regression có Accuracy CV 0,823 và F1 CV 0,763, nhỉnh hơn các mô hình còn lại theo hai chỉ số này. Như vậy kết quả phụ thuộc chỉ số đánh giá: mô hình dẫn đầu ROC-AUC không nhất thiết dẫn đầu Accuracy hoặc F1. Cross-validation là ước lượng trên nhiều fold, tránh đưa ra lựa chọn dựa trên một lần chia dữ liệu.

3.17. Hyperparameter tuning bằng RandomizedSearchCV

Notebook dùng RandomizedSearchCV trên tập huấn luyện với Stratified 5-Fold, tối ưu ROC-AUC cho từng mô hình. Việc so sánh không sử dụng điểm validation để quyết định bộ tham số.

Kết quả ROC-AUC CV sau tuning và tham số tốt nhất

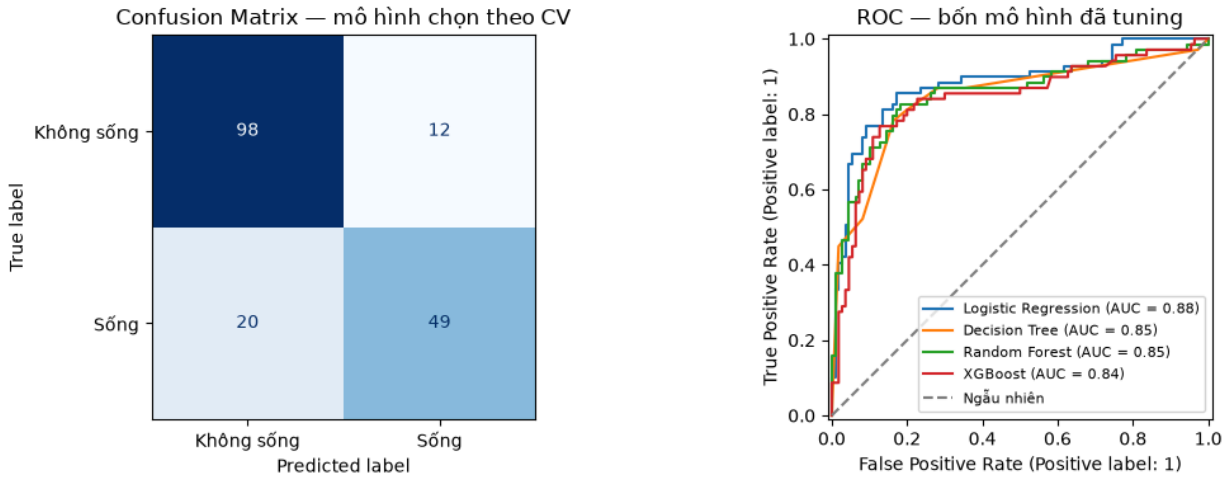
Mô hình	ROC-AUC CV sau tuning	Tham số tốt nhất
XGBoost	0.8907	{'mo_hinh__subsample': 1.0, 'mo_hinh__reg_lamb...
Random Forest	0.8866	{'mo_hinh__n_estimators': 300, 'mo_hinh__min_s...
Logistic Regression	0.8664	{'mo_hinh__class_weight': None, 'mo_hinh__C': 10}
Decision Tree	0.8647	{'mo_hinh__min_samples_split': 20, 'mo_hinh__m...

Sau tuning, XGBoost đứng đầu theo ROC-AUC CV = 0,890712; Random Forest = 0,886611; Logistic Regression = 0,866436; Decision Tree = 0,864687. Vì tiêu chí lựa chọn định trước là ROC-AUC CV, notebook chọn XGBoost. Việc tune giúp Decision Tree cải thiện đáng kể ROC-AUC CV so với ban đầu, trong khi Logistic Regression gần như không đổi. Kết quả cao nhất sau tuning là trên các fold huấn luyện, không phải điểm xác nhận độc lập trên test.csv của Kaggle.

3.18. Đánh giá cuối cùng trên tập validation

Bảng chỉ số validation của cả bốn mô hình

Mô hình	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.855	0.841	0.768	0.803	0.882
Random Forest	0.821	0.803	0.71	0.754	0.855
Decision Tree	0.816	0.75	0.783	0.766	0.845
XGBoost	0.821	0.803	0.71	0.754	0.839



Hình 15. Confusion Matrix và ROC Curve của mô hình được chọn

Trên 179 quan sát validation, Logistic Regression đạt ROC-AUC 0,882 và Accuracy 0,855; XGBoost đạt ROC-AUC 0,839 và Accuracy 0,821. Đây là sự khác nhau giữa thứ hạng CV và validation: XGBoost vẫn là mô hình được chọn theo CV đã định trước, nhưng không phải mô hình tốt nhất trên validation theo các chỉ số vừa nêu. Việc Logistic Regression vượt XGBoost trên holdout cho thấy chọn mô hình theo CV không đảm bảo sẽ đứng đầu trên một lần chia validation. Không nên đổi tiêu chí lựa

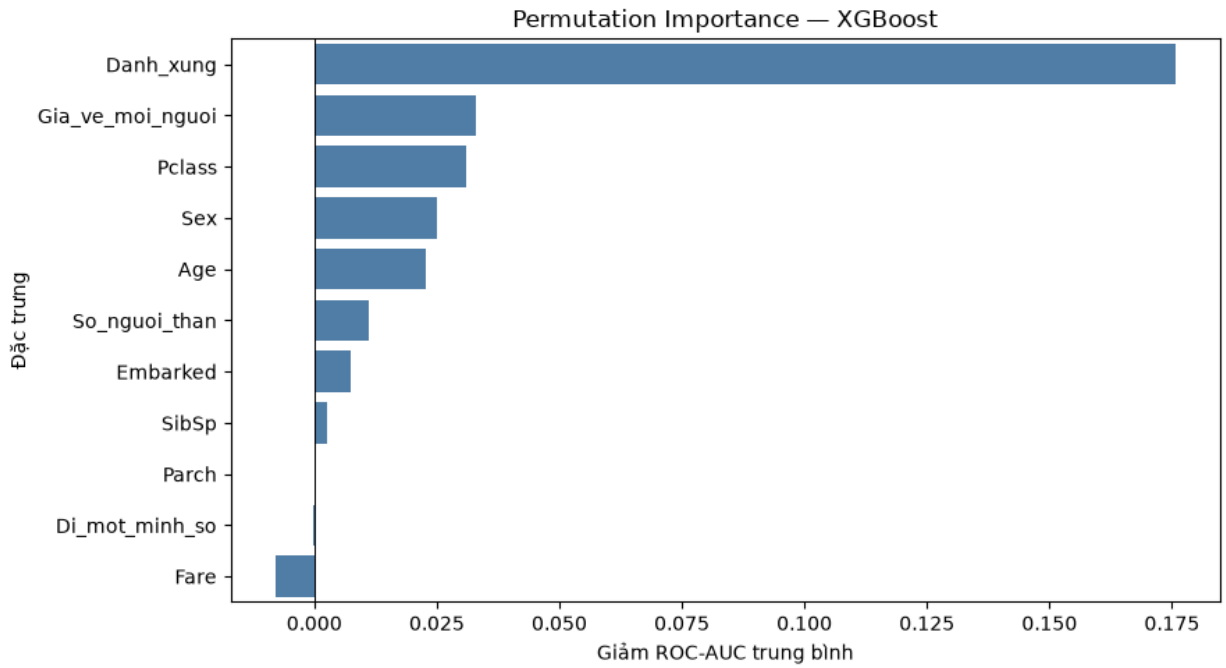
chọn sau khi xem validation; thay vào đó báo cáo cả hai và kiểm tra tính ổn định nếu mở rộng nghiên cứu.

Classification report của XGBoost cho lớp sống sót: Precision ≈0,80, Recall ≈0,71 và F1 ≈0,75. Điều này cho thấy vẫn còn người sống sót thực tế bị dự đoán bỏ sót. Recall khoảng 0,71 cho lớp sống sót nghĩa là vẫn có trường hợp sống sót không được mô hình nhận diện. Confusion Matrix cho cái nhìn theo số lượng từng loại dự đoán, bổ sung cho ROC-AUC là chỉ số xét nhiều ngưỡng.

3.19. Giải thích mô hình tốt nhất bằng Permutation Importance

Tầm quan trọng đặc trưng theo mức giảm ROC-AUC

Đặc trưng	Giảm ROC-AUC trung bình	Độ lệch chuẩn
Danh_xung	0.1756	0.0417
Gia_ve_moi_nguoi	0.0331	0.0112
Pclass	0.031	0.0087
Sex	0.025	0.0134
Age	0.0227	0.0092
So_nguoi_than	0.0111	0.0055
Embarked	0.0075	0.0064
SibSp	0.0025	0.0016
Parch	0.0001	0.001
Di_mot_minh_so	-0.0002	0.0003
Fare	-0.0079	0.0074



Hình 16. Permutation Importance trên tập validation

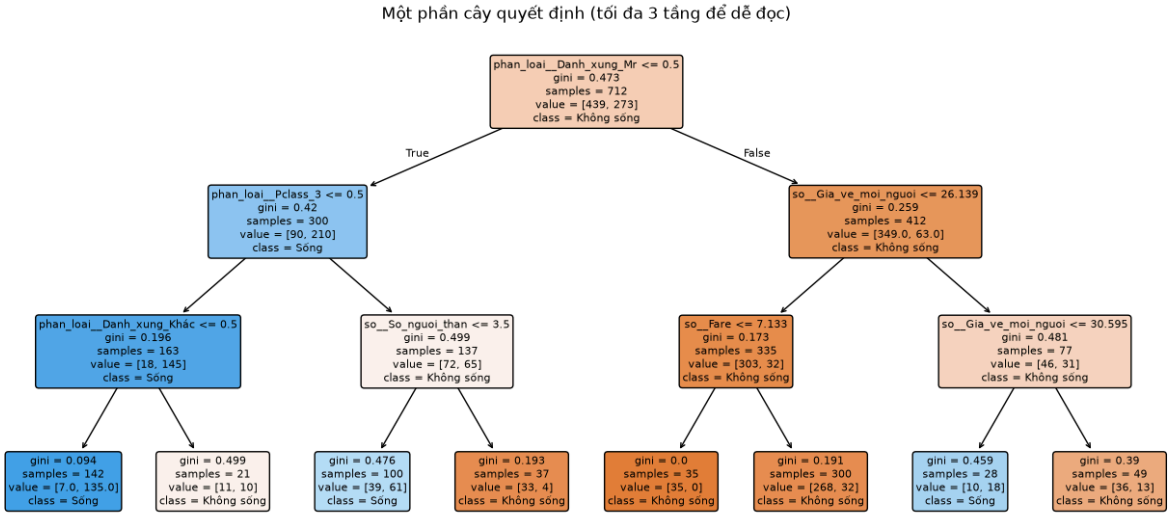
Danh_xung là đặc trưng quan trọng nhất khi xáo trộn độc lập (giảm ROC-AUC trung bình 0,1756), tiếp theo là Gia_ve_moi_nguoi 0,0331, Pclass 0,0310, Sex 0,0250 và Age 0,0227. Tầm quan trọng này là của mô hình và tập kiểm tra cụ thể; các đặc trưng tương quan có thể chia sẻ đóng góp. Permutation Importance đo độ suy giảm điểm khi xáo trộn từng cột trên tập validation. Danh_xung có thể chia sẻ thông tin với Sex nên điểm quan trọng không được hiểu là đóng góp nhân quả tách biệt; kết quả còn phụ thuộc mô hình, tập dữ liệu và phép đo.

3.20. Diễn giải bổ sung: Logistic Regression và cây quyết định

Hệ số Logistic Regression có độ lớn tuyệt đối cao

Đặc trưng sau xử lý	Hệ số	Độ lớn tuyệt đối
phan_loai__Danh_xung_Master	2.388	2.388
phan_loai__Sex_female	1.706	1.706
phan_loai__Sex_male	-1.394	1.394
phan_loai__Pclass_1	1.166	1.166
phan_loai__Danh_xung_Miss	-0.933	0.933
phan_loai__Pclass_3	-0.912	0.912
phan_loai__Danh_xung_Mr	-0.649	0.649

phan_loai__Embarked_Q	0.432	0.432
so__SibSp	-0.381	0.381
so__Age	-0.36	0.36
so__So_nguoi_than	-0.33	0.33
phan_loai__Danh_xung_Mrs	-0.284	0.284
phan_loai__Embarked_S	-0.222	0.222
phan_loai__Danh_xung_Khác	-0.21	0.21
so__Di_mot_minh_so	-0.196	0.196



Hình 17. Hệ số Logistic Regression và cây quyết định được trực quan hóa

Hệ số Logistic Regression cung cấp hướng liên hệ có điều kiện theo cách mã hóa biến và chuẩn hóa đang dùng; độ lớn hệ số không đồng nghĩa mức độ tác động nhân quả. Cây quyết định minh họa những quy tắc tách nhóm học được từ dữ liệu huấn luyện. Dấu của hệ số logistic cần đọc theo mức tham chiếu sau One-Hot Encoding, còn độ lớn hệ số phụ thuộc thang đo. Cây quyết định diễn giải quy tắc dự đoán theo các nhánh nhưng không thay thế được kiểm định nhân quả.

3.21. Kiểm tra overfitting: so sánh train và validation nội bộ của mô hình đã chọn

XGBoost được chọn đạt ROC-AUC train = 0,982, validation = 0,839, chênh 0,143. Khoảng cách này là dấu hiệu mô hình có thể overfit; cần ưu tiên đánh giá trên dữ liệu chưa gặp và thử đơn giản hóa mô hình hoặc điều chỉnh regularization trong các nghiên cứu tiếp theo. Khoảng cách 0,143 là tương đối lớn với dữ liệu chỉ 891 dòng, cho

thấy mô hình có khả năng học quá sát tập train. Có thể thử giảm độ sâu cây, tăng regularization hoặc kiểm tra lại bằng nhiều lần chia và cross-validation lồng nhau.

3.22. Dự đoán trên test.csv chính thức của Kaggle và xuất submission.csv

Notebook đọc trực tiếp 418 hành khách từ test.csv (không có Survived), huấn luyện lại mô hình được chọn trên toàn bộ train.csv và xuất submission.csv gồm PassengerId và Survived. Có 153/418 hành khách được dự đoán sống sót; đây là kết quả dự đoán, không phải tỷ lệ sống sót đã kiểm chứng trên nhãn thật. Tỷ lệ dự đoán sống sót khoảng 36,6% (153/418), nhưng đó chỉ là dự đoán của mô hình trên hành khách chưa biết kết quả. Không được suy ra tỷ lệ sống thực tế hay tính Accuracy chính thức khi chưa có nhãn từ Kaggle.

Năm dòng đầu của submission.csv

PassengerId	Survived
892	0
893	0
894	0
895	0
896	1

KẾT LUẬN, HẠN CHẾ VÀ KHUYẾN NGHỊ

Phát hiện chính

Tỷ lệ sống sót chung là 38,4%. Có sự khác biệt rõ theo giới tính và hạng vé: nữ 74,2% so với nam 18,9%; hạng 1 đạt 63,0% so với hạng 3 là 24,2%. Khi xét đồng thời giới tính và hạng vé, nữ hạng 1 có tỷ lệ sống 96,8%, còn nam hạng 3 là 13,5%.

Nhóm đi cùng 1-2 người thân đạt 56,3%, cao hơn các nhóm quy mô khác trong mẫu. Các phân tích về tuổi, danh xưng, cảng lên tàu và giá vé trong từng hạng gợi ý các khác biệt bổ sung; không được kết luận nguyên nhân trực tiếp từ các so sánh quan sát này.

Kết quả dự đoán và ý nghĩa ứng dụng

Trong bốn mô hình đã tinh chỉnh, XGBoost tốt nhất theo ROC-AUC cross-validation (0,891), nhưng Logistic Regression đạt kết quả tốt hơn trên validation (ROC-AUC 0,882 so với 0,839). Do đó, báo cáo phân biệt rõ tiêu chí chọn mô hình từ CV và đánh giá độc lập cuối cùng. Kết quả phục vụ học tập về phân loại và so sánh mô hình, không nên dùng để suy ra quy trình cứu hộ cụ thể.

Giới hạn dữ liệu và phương pháp

- Age thiếu 19,87% và Cabin thiếu 77,10%; phân tích tuổi chỉ dựa trên 714 quan sát có tuổi.
- Những nhóm ít người, ví dụ nữ hạng 1 ≤12 tuổi hoặc nhóm trên 60 tuổi, có tỷ lệ không ổn định; cần xem kích thước mẫu và CI.
- Dữ liệu không cung cấp thời điểm sơ tán, vị trí thực tế và việc tiếp cận xuồng cứu sinh; không suy luận nhân quả từ thống kê quan sát.
- Kích thước tập huấn luyện chỉ 891 người; độ lệch giữa ROC-AUC train và validation của XGBoost cho thấy nguy cơ overfitting.
- test.csv của Kaggle không có nhãn Survived nên chưa tính được Accuracy hay ROC-AUC chính thức trên tập này.

Khuyến nghị và hướng mở rộng

Đối với phân tích an toàn hệ thống, cần chú ý khả năng tiếp cận lối thoát hiểm và hỗ trợ các nhóm hành khách khác nhau, nhưng mọi khuyến nghị vận hành phải được kiểm chứng bằng dữ liệu hoặc tài liệu lịch sử bổ sung.

Có thể kiểm tra khoảng tin cậy theo các nhóm hiếm, thử các đặc trưng ít phụ thuộc lẫn nhau, đánh giá calibration, tăng regularization để giảm overfitting và sử dụng

nested cross-validation nếu cần ước lượng tổng quát hóa chặt chẽ hơn. Nếu nộp Kaggle, chỉ báo cáo điểm leaderboard sau khi thực sự nhận được.

PHỤ LỤC. CÁC BẢNG THỐNG KÊ BỔ SUNG

A.1. Năm dòng đầu train.csv

Để bảo toàn đủ 12 thuộc tính và tránh bảng quá hẹp, năm bản ghi đầu được chia thành hai bảng có cùng PassengerId.

Bảng A1a. Thông tin hành khách và trạng thái

PassengerId	Survived	Pclass	Name	Sex	Age
1	0	3	Braund, Mr. Owen Harris	male	22
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38
3	1	3	Heikkinen, Miss. Laina	female	26
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35
5	0	3	Allen, Mr. William Henry	male	35

Bảng A1b. Nhóm gia đình và thông tin vé

PassengerId	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	1	0	A/5 21171	7.25	—	S
2	1	0	PC 17599	71.2833	C85	C
3	0	0	STON/O2. 3101282	7.925	—	S
4	1	0	113803	53.1	C123	S
5	0	0	373450	8.05	—	S

A.2. Thống kê mô tả toàn bộ 12 biến

Bảng A2a. Số lượng, nhóm giá trị và trung bình

Thuộc tính	count	unique	top	freq	mean	std

PassengerId	891	—	—	—	446	257.3538
Survived	891	—	—	—	0.3838	0.4866
Pclass	891	—	—	—	2.3086	0.8361
Name	891	891	Braund, Mr. Owen Harris	1	—	—
Sex	891	2	male	577	—	—
Age	714	—	—	—	29.6991	14.5265
SibSp	891	—	—	—	0.523	1.1027
Parch	891	—	—	—	0.3816	0.8061
Ticket	891	681	347082	7	—	—
Fare	891	—	—	—	32.2042	49.6934
Cabin	204	147	G6	4	—	—
Embarked	889	3	S	644	—	—

Bảng A2b. Phân vị và giá trị biên

Thuộc tính	min	25%	50%	75%	max
PassengerId	1	223.5	446	668.5	891
Survived	0	0	0	1	1
Pclass	1	2	3	3	3
Name	—	—	—	—	—
Sex	—	—	—	—	—
Age	0.42	20.125	28	38	80
SibSp	0	0	0	1	8
Parch	0	0	0	0	6
Ticket	—	—	—	—	—
Fare	0	7.9104	14.4542	31	512.3292
Cabin	—	—	—	—	—
Embarked	—	—	—	—	—

A.3. Năm dòng sau tiền xử lý

Bảng A3. Bản ghi đã tạo đặc trưng

Survived	Sex	Pclass	Age	Nhom_tuoi	So_nguoi_than	Embarked
0	male	3	22	19-35	1	S
1	female	1	38	36-60	1	C
1	female	3	26	19-35	0	S

1	female	1	35	19-35	1	S
0	male	3	35	19-35	0	S

A.4. Diễn giải các kết quả từ notebook

Các bảng kiểm định, thống kê nhóm, hệ số, bảng dự đoán và toàn bộ 17 biểu đồ đã được đặt ở đúng mục phân tích tương ứng trong báo cáo. Nội dung và giá trị được lấy trực tiếp từ outputs đã lưu trong notebook, không ước đoán các số còn thiếu.

TÀI LIỆU

1. Kaggle. Titanic - Machine Learning from Disaster.
https://www.kaggle.com/competitions/titanic/data

2. Repository dữ liệu và notebook: https://github.com/hnhun2306b5tneu-crypto/Titanic